

二、研究計畫內容（以 10 頁為限）：

（一）摘要

隨著健身訓練和競技運動越來越強調量化與科學化，要怎麼客觀且有效地評估動作品質，已經成為運動科技中一個重要的問題。以舉重等健身運動來說，初學者往往只能透過錄製自己的動作並與網路上的影片作比較，這不僅主觀、效率低且容易忽略細節。動作品質評估（Action Quality Assessment, AQA）是透過數據來評估動作做得好不好，在缺乏專業教練的情況下，能提供使用者接近專家裁判水準的評分結果。然而，目前的 AQA 方法多著重於分數預測，雖然可以準確區分動作好壞，卻難以解釋評分原因，更無法提供具體且可執行的修正建議，因此在實際訓練和教學應用中無法發揮其價值。

AQA 是利用深度學習的技術，透過評分的方式來說明動作的正確性。雖然在評分任務上幾乎可以達到與人類裁判相同的程度，卻沒有辦法解釋分數是如何得到的，屬於僅能給出分數卻無法提供具體修正指導的評估方法。另一方面，大型語言模型（LLM）雖然可以建議使用者改進的方向，但在缺乏運動生物力學等專業領域知識下，常面臨內容準確性不足，甚至產生幻覺的風險。本計畫目標結合兩者優勢並克服其缺陷，提出一套 AI 教練框架，透過結合視覺與知識檢索增強生成（RAG[1]）技術，開發出一個既能精確診斷動作細節，且提供具備生物力學依據、精確無幻覺指導建議之系統。

（二）研究動機與研究問題

隨著健康意識的抬頭與競技體育的科學化發展，大眾對於運動訓練品質的要求日漸增加。然而，專業的運動教練資源稀少且昂貴，使得大多數喜歡運動的人或基層運動員難以獲得即時、一對一的專業指導。在缺乏教練的情況下，錯誤的動作模式不僅會降低訓練效率，更可能導致長期的運動傷害。

雖然市面上已經有許多基於電腦視覺的運動健身的應用程式，但大多數只能提供一般的計數功能、簡單的姿勢比對或虛擬訓練的體驗。例如自行車虛擬騎行的應用程式如 Zwift、Rouvy、WhizU，能夠模擬真實路線、監測功率數據並支援多人團騎，帶來沉浸式的訓練樂趣[2]。又如喬山魔鏡（Johnson@Mirror）[3]等智能健身鏡，提供鏡面互動課程、即時動作計數與基本姿勢提示，卻無法針對動作細節（如膝蓋內扣、骨盆傾角等）進行精確的生物力學診斷，而其價格昂貴且佔空間。這些產品雖提升了居家訓練的便利性與趣味性，卻無法像人類教練一樣，提供深入、可解釋且安全的專業指導。因此，開發一個具備高度可解釋性、能結合視覺診斷與權威知識庫、並提供專業建議的 AI 教練系統，具有極大的市場需求與應用價值。

傳統 AQA 技術的黑盒子困境


在電腦視覺領域，AQA 已經是一個熱門的研究方向。目前主流方法通常使用深度學習模型（如基於骨架的圖卷積網路 GCN），透過大量學習裁判或專業教練標註的數據，訓練模型預測動作的分數。這些模型在評分任務上已能達到與人類裁判高度相關的準確度。

然而，這類方法存在一個致命的缺點：**缺乏可解釋性**。也就是 AI 僅能給出結果，卻無法清楚說明原因。舉例來說，模型雖然能精確算出一個深蹲動作是 60 分，卻無法告訴使用者為什麼是 60 分以及如何做到 90 分。對於運動員而言，單純的一個分數是毫無指導意義的，他們需要的是具體的回饋，

例如膝蓋內扣幅度過大(如圖一)或肩胛骨沒有收緊(如圖二)。目前的 AQA 技術就像一位沈默的裁判，只舉牌打分卻不說話，而這與真正教練的角色相去甚遠。



圖一：膝蓋內扣示意圖。左側為正常膝關節對齊（綠色標記），右側為膝蓋內扣（knee valgus，紅色標記）。（圖片來源：https://www.youtube.com/watch?v=wJyJUUV_7DA）



圖二：肩胛骨沒有收緊示意圖。左側為肩胛骨沒有收緊（紅色標記），右側為正常臥推姿勢。（圖片來源：<https://builtwithscience.com/fitness-tips/how-to-properly-bench-press/>）

多模態模型的局限：幻覺與專業性不足

隨著大型語言模型與多模態大模型（例如 GPT-4V, LLaMA-Vision）的興起，AI 展現了驚人的圖文理解與生成能力。理論上，我們可以將運動影片輸入給多模態模型，讓它生成指導建議。然而，在實際應用上，這些通用模型面臨兩大挑戰：

- 缺乏領域知識和精確度不足

通用模型雖然看過大量數據，但在特定的運動生物力學領域往往不夠精確，例如它可能能辨識出人在舉重，但無法精確判斷抓舉過程中膝蓋二次彎曲的時機是否正確。

- 幻覺問題

這是目前生成式 AI 在教學場景中最大的隱憂。當模型不確定時，往往會一本正經地胡說八道，給出違反人體力學甚至危險的建議。例如，建議使用者在不該發力的時候用力，這對於依賴 AI 進行訓練的使用者來說風險很高的。通用模型就像一位博學但非專業的觀眾，能說出大致的樣子，但給出的建議卻缺乏理論依據，且容易出錯。

解決方法：RAG 與視覺推理的結合

根據上述原因，我們認為必須結合精確的視覺感知和領域的知識，需要一個系統，既能像電腦視覺模型一樣精確捕捉關節角度與時間序列特徵；又能像專業教練一樣，依據教科書、規則手冊或生物力學文獻來進行推理。

透過 RAG 技術，我們可以將 AI 的回答限制在權威知識庫的範圍內。當系統檢測到視覺特徵（如膝蓋內扣）時，它不應該憑空生成建議，而是先從向量資料庫中找尋相關的生物力學原理與糾正方法，再將這些證據交由語言模型並生成人類可讀的建議。這不僅解決了幻覺問題，更實現了 AI 教練的有據可依，讓每一條建議都能追溯到具體的文獻來源。

(三) 文獻回顧與探討

在 AQA 研究中，傳統基於像素的方法易受背景雜訊干擾且缺乏語意解釋，因此近年的研究多轉向基於骨架的方法[4]。通過 OpenPose 或 HRNet 等姿態估計技術提取人體關鍵點，並將其轉換為圖結構，利用時空圖卷積網絡（Spatial Temporal Graph Convolutional Networks, ST-GCN）來分析關節的運動學特徵。

- Hierarchical 建立模型：Zhou 等人提出的 Hierarchical GCN[5]進一步將動作分解為不同的語意層次，從局部關節運動到全身協調，這對於捕捉像體操或花式滑冰這樣複雜動作的細微失誤至關重要。
- 生物力學數據的橋樑：骨架數據是連接視覺與生物力學知識的理想橋樑，因為膝蓋角度、軀幹傾角等關鍵參數，可以直接從骨架坐標中計算得出，為後續的規則判定提供了數據基礎。

儘管基於骨架的模型在抗干擾能力和隱私保護上有所提升，但傳統 AQA 系統在教練角色上仍顯不足。它們擅長診斷（指出哪裡錯了），卻無法給出處方（如何改）。更關鍵的是，目前的模型大多缺乏因果推理能力，無法解釋錯誤之間的連鎖反應（例如：因為核心力量不足導致起跳高度不夠，進而導致空中翻騰圈數不足）。顯示了單純依靠數據的深度學習模式已觸及瓶頸，必須引入外部的 Domain Knowledge 來補足推理能力的缺失。

多模態推理與視覺-語言對齊

要實現能夠具體指出問題的 AI 教練，核心在於讓機器理解專業的運動細節，這涉及電腦視覺與自然語言處理的交叉領域：視覺-語言對齊。

預訓練的視覺語言模型（如 CLIP[6], ALIGN[7]）雖然掌握了豐富的通用概念，但在面對 fine-grained 的運動分析任務時往往表現不夠好，它們擅長捕捉全域動作（像是辨識出網球發球），但難以捕捉細微的局部幾何特徵（像是手腕過度伸展 5 度）。

為了解決 fine-grained 動作辨別問題，本計畫參考 HAKE[8]的肢體狀態分解概念 及 MotionGPT[9]的多模態推理架構，以強化模型對微小錯誤的感知能力。

知識增強與可解釋性 AI (XAI)

為了避免幻覺並提供專業依據，AI 教練必須閱讀過規則，而這需要建立專門的知識庫（Knowledge Base, KB）並且結合 RAG。

一個專業的知識庫是可解釋性的基礎，必須包含非結構化的文本和結構化的圖：

- 運動的概念[10]：定義領域內的概念及其關係，如解剖結構、訓練處方、以及錯誤類型。
- 知識來源：包含權威機構，例如：National Strength and Conditioning Association (NSCA)、美國運動醫學會 (ACSM) 的訓練指南、生物力學論文，以及具體的運動規則手冊。
- 知識圖譜 (Knowledge Graph, KG)：從文獻中提取動作與關係 (如：膝外翻→導致→ACL→受傷風險)。KG 不僅儲存知識，更能做到一層一層的推理，幫助系統找到錯誤的原因。

傳統 RAG 針對的是文本查詢，而 AI 教練面對的是影片或動作的查詢，因此需要設計專門的架構：

- Video-to-Text Bridge：先利用視覺 encoder 將用戶的動作變成結構化的文字描述 (如檢測到骨盆後傾)。
- GraphRAG 推理：當系統檢索到骨盆後傾時，透過 KG 遍歷其鄰居節點，檢索潛在原因 (如腿後肌群過緊) 和解決方案 (如靜態拉伸訓練)。
- 規則與技巧：知識庫應區分規則 (違規即零分) 和技巧 (影響效率但非違規)，引導 LLM 生成不同語氣的建議。

通過引入知識庫，LLM 的生成過程受到嚴格的事實依據約束。RAG 框架將 LLM 從一個憑空回答的百科全書變成一個基於參考資料的助理。每生成一條建議，系統都能提供對應的參考文獻或規則條款作為依據，這極大提升了使用者的信任度與系統的專業權威性。

實際案例比較

本計畫整合多模態感知與生成式 AI 技術，相較於現有 AQA 系統具備顯著優勢。回顧過往大專生計畫，「基於 OpenPose 高爾夫動作評分」[11]僅以 OpenPose 進行骨架比對並提供分數與視覺誤差，卻缺乏語意解釋。本計畫使用 RAG 與 LLM，可以結合生物力學知識，具體指出如膝蓋內扣導致 ACL (前十字韌帶) 受傷風險等可操作的修正建議，實現高解釋性。

相較於「生成式 AI 互動虛擬健身教練」[12]雖具互動性但依賴通用 LLM 易產生幻覺，本計畫透過 RAG 強制模型檢索專業文獻，確保建議符合運動科學原理，提升專業性與安全性。

表一：現有 AQA 系統和本計畫之比較

特徵	傳統 AQA (如 OpenPose 高爾夫[11])	通用 AI (如 互動虛擬健身教練[12])	本計畫 (RAG + Multimodal)
核心技術	骨架比對、迴歸分析	通用 LLM、基礎視覺辨識	RAG + 多模態 LLM
回饋形式	分數、視覺標註	通用建議、基礎計數	解釋性建議
專業依據	僅依賴數據模型差異	依賴模型預訓練資料 (易幻覺)	依賴專業文獻知識庫 (有據可依)
解釋能力	低 (只知好壞，不知原因)	中 (有解釋，但不一定準確)	高 (精確指出錯誤原因與修正法)

(四) 研究方法及步驟


資料收集與知識庫建立

本計畫將聚焦於健身房最常見且風險較高的三項動作：深蹲（Squat）、臥推（Bench Press）與硬舉（Deadlift），所需數據分為視覺影像與專業領域知識兩部分，以支撐多模態模型的訓練與檢索需求。

- 視覺影像數據：採用公開的 FLEX dataset[13]與 Fitness-AQA dataset[14]。FLEX 和 Fitness-AQA 包含豐富的健身動作標註，而本計畫主要關注的深蹲、臥推、硬拉等核心動作在這兩個公開 dataset 至少有 1,000 段影片，能讓模型學習基礎的動作語意理解能力。
- 專業領域知識數據：將 NSCA、ACSM 等文獻進行文本切塊，並利用 LLM 抽取出錯誤動作與修正處方之間的因果關係，建立如「膝蓋內扣→導致→ACL 受傷風險」的 Knowledge Graph。

系統架構設計

本計畫提出的 AI 教練系統的系統架構由（1）多模態感知模組；（2）語義 RAG 模組；（3）推理與生成模組；（4）互動式前端，四個部分組成。系統架構圖如圖三所示。



圖三：系統架構

1. 多模態感知模組：

- 幾何邏輯：關注「身體怎麼動、關節怎麼對齊」

使用 MediaPipe，透過計算關鍵點之間的歐幾里得距離、向量夾角與相對位置，直接判定肢體狀態。例如：不需訓練模型辨識膝蓋彎曲，直接計算（髌-膝-踝）夾角，若小於 160 度即標記為膝蓋彎曲(如圖四)。



圖四：深蹲分析示意圖。系統透過 MediaPipe 捕捉關鍵點，並計算膝蓋與腳踝夾角以判定是否發生「膝蓋內扣」錯誤。(原圖來源：Unsplash，攝影者：John Wallace)

- 時空特徵：關注「動作看起來對不對、順不順」

我們將預訓練的 VideoMAE V2[15]作為特徵提取，針對 FLEX Dataset 與 Fitness-AQA dataset 進行 Downstream Fine-tuning，並使用對比學習，拉近標準動作與高分動作的特徵距離，並推遠錯誤動作的距離以捕捉細節。

2. 語意 RAG 模組：

- 建立領域專用的向量資料庫，儲存運動生物力學規則、解剖學知識與訓練處方。
- 使用 FLEX dataset 中的 Fitness Knowledge Graph (FKG)，使用結構化的方式將動作→錯誤→改正方向連結在一起，並依據最新運動科學期刊與文獻，動態擴充與更新圖的節點。
- 將感知模組輸出的幾何狀態轉化為結構化文本描述，接著以文本作為 Query，在向量資料庫與 KG 中檢索對應的糾正知識（例如：膝內扣角度過大導致臀中肌無力）。

3. 推理與生成模組：

作為 AI 教練的大腦，負責將感知層的視覺特徵與 GraphRAG 檢索到的知識進行語意融合，並基於 LLaMA-3 (8B)[16]或 Qwen-2.5[17]進行提示工程，生成具備專業教練口吻的結構化回饋。

1) 輕量化視覺-語言 Adapter

使用預訓練投影層結合微調策略，設計一個 Multilayer Perceptron (MLP) 作為連接層，將 VideoMAE 輸出的高維時空特徵與 MediaPipe 提取的幾何特徵映射至 LLM 的 Token Embedding Space。

2) 設計提示工程

為了讓模型生成精確的糾錯建議，設計了包含四個種類的輸入 prompt：

- 角色設定：定義模型為「具備生物力學知識的資深健身教練」，要求語氣鼓勵且專業。
- Adapter 輸出：包含動作片段的視覺特徵，以及由感知模組標記的錯誤資訊。
- RAG：由 GraphRAG 檢索到的生物力學原理（例如：「膝內扣會增加 ACL 壓力，通常由臀中肌無力引起」）。
- 用戶指令：用戶的問題（例如：「我的深蹲哪裡怪怪的？」）。

3) 設計結構化 CoT

為確保輸出內容符合教學邏輯，強迫模型遵循「觀察→原因→糾正」的 CoT (Chain-of-Thought) 進行生成，並輸出結構化格式（如 JSON）：


- 找出錯誤（觀察）：指出感知模組捕捉到的具體錯誤時間點（例如：「在 00:03 下蹲最低點時...」）。
- 解釋原因（原因）：結合 RAG 得到的錯誤發生的生物力學成因（例如：「...您的膝蓋向內塌陷，這顯示臀部外展肌群未正確啟動」）。
- 糾正建議（糾正）：提供具體可執行的行動指令（例如：「試著在膝蓋套上彈力帶，下蹲時想像將彈力帶撐開」）。

4. 互動式前端：

負責多模態資訊的可視化呈現與使用者交互，提供直觀的即時教學體驗。

- 動作可視化與標註：
 - 骨架疊加：將 MediaPipe 提取的關鍵點即時呈現於螢幕上。
 - 錯誤追蹤：自動標記錯誤姿勢（如紅框顯示膝內扣），並在時間軸上註記錯誤片段。
- 結構化回饋介面：
 - 結構化建議展示：將 LLM 生成的內容轉化為「觀察、原因、建議」三段式卡片，確保指引易於閱讀。
 - 多輪對話：支援使用者追問細節，串聯 RAG 資料庫提供具文獻依據的深度解答。

下方圖五為本計畫預計開發之 AI 教練系統互動介面原型，左側（圖五紅框處）為即時骨架與錯誤偵測，右側（圖五藍框處）為基於 RAG 生成之具體修正建議與文獻依據。



圖五：AI 教練系統互動介面原型

評估指標與驗證方法

- 動作評分一致性：

使用 Spearman 相關係數 ρ (Spearman's Rank Correlation)[18]，驗證 AI 模型輸出的動作評分與人類裁判 (Ground Truth) 之間的排序一致性，證明系統能像人類專家一樣準確區分動作優劣，而非僅學習到背景雜訊。

- RAG 生成品質與幻覺檢測：

採用 RAGAS (Retrieval Augmented Generation Assessment) [19]評估框架。檢測生成的建議是否嚴格基於檢索到的生物力學文獻，以及 GraphRAG 是否能精準抓取與視覺錯誤特徵 (如膝內扣)。

- 使用者體驗回饋：

本計畫將邀請 3-5 位具備專業證照之健身教練或體育領域專家，針對 AI 系統生成的錯誤偵測結果與修正建議進行專業度評分。計算 AI 判讀結果與專家判讀結果之 Cohen's κ 係數[20]，以驗證系統輸出是否具備專家水準的可信度。

- 系統可用性測試：

針對系統介面進行小規模的可用性測試。邀請使用者操作 Web 介面，評估骨架視覺化呈現與文字建議的清晰度與易讀性，針對系統介面操作流程進行回饋收集。

本計畫研究期程之甘特圖：

時間 任務	115 年						116 年	
	7 月	8 月	9 月	10 月	11 月	12 月	1 月	2 月
收集影片、文獻等資料								
建立 KG 架構								
部署 MediaPipe 與幾何邏輯								
訓練 VideoMAE 提取時空特徵								
建立 RAG 向量資料庫								
建立 Graph Database								
訓練視覺-語言 Adapter								
設計提示工程與 CoT								
端對端系統整合								
開發前端視覺化介面								
使用者體驗回饋收集								
系統性能優化與調整								

(五) 預期結果

本計畫預期成功開發出一套結合多模態視覺感知與生物力學知識的可解釋性 AI 教練系統原型。透過導入 GraphRAG 技術，我們將有效解決通用語言模型在運動指導上的幻覺問題確保每一條建議皆來自權威文獻與規則手冊，實現真正有據可依的專業指導。

在應用層面，系統將能精確辨識深蹲、臥推及硬舉的細微錯誤（如膝蓋內扣的具體時機），並突破傳統 AQA 僅能評分的限制，生成包含錯誤原因（如臀中肌無力）與修正處方的建議。最終成果將包含完整的 Web 互動介面，整合骨架視覺化與對話式指導，預期能大幅降低大眾獲取專業教練資源的門檻，提供安全且科學化的個人運動輔助。

(六) 需要指導教授指導內容

- 引導使用台灣博碩士論文知識加值系統，蒐集相關文獻。
- MediaPipe 使用等相關協助

- 功能型設備呈現與 UI 介面設計
- 系統整合
- 成果報告撰寫
- 延伸此系統未來應用的更多發展

(七) 參考文獻

- [1] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., ... van der Wal, D. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks* (arXiv:2005.11401). arXiv. <https://arxiv.org/abs/2005.11401>
- [2] CyclingTime.com. (n.d.). Zwift、Rouvy、WhiizU，線上軟體你的選擇？-單車時代 CYCLINGTIME.com 自行車賽事報導、單車環島路線、新手教學. Retrieved February 5, 2026, CyclingTime.com. <https://cyclingtime.com/tw/documents/10923.html>
- [3] Johnson Fitness & Wellness Taiwan. (n.d.). Johnson@Mirror 新概念健身魔鏡 - JOHNSON 喬山 健康科技. Retrieved February 5, 2026, Johnson Fitness & Wellness Taiwan. <https://www.johnsonfitness.com.tw/prod/?q=MIRROR-relax>
- [4] Qiu, J., & Wang, L. (2025). Evolving skeletons: Motion dynamics in action recognition (arXiv:2501.02593v1). arXiv. <https://arxiv.org/html/2501.02593v1>
- [5] Zhou, Kanglei. (n.d.). HGCN_AQA [Source code]. GitHub. Retrieved February 5, 2026, from https://github.com/ZhouKanglei/HGCN_AQA
- [6] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning* (Vol. 139, pp. 8748–8763).
- [7] Jia, C., Yang, Y., Xia, Y., Chen, Y.-T., Parekh, Z., Pham, H., Le, Q. V., Sung, Y.-H., Li, Z., & Duerig, T. (2021). Scaling up visual and vision-language representation learning with noisy text supervision. In *Proceedings of the 38th International Conference on Machine Learning* (Vol. 139, pp. 4904–4916).
- [8] Li, Y.-L., Liu, X., Wu, X., Li, Y., Qiu, Z., Xu, Y., Fang, H.-S., & Lu, C. (2023). A knowledge engine foundation for human activity understanding. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. <https://pubmed.ncbi.nlm.nih.gov/37819797/>
- [9] Jiang, B., Chen, X., Liu, W., Yu, J., & Chen, T. (2023). MotionGPT: Human motion as a foreign language. In *OpenReview*. <https://openreview.net/pdf?id=WqiZJGNkjin>
- [10] National Center for Biomedical Ontology. (n.d.). Ontology for Physical Exercise (OPE). BioPortal. Retrieved February 5, 2026 <https://bioportal.bioontology.org/ontologies/OPE>

- [11] 王旻玄 (2023). 基於 OpenPose 深度學習之影像辨識進行動作評分-以高爾夫球為例 (國家科學及技術委員會補助大專學生研究計畫成果報告, NSTC 111-2813-C-005-029-E). 國家科學及技術委員會
- [12] 呂昱萱 (2025). 生成式 AI 互動虛擬健身教練 (國家科學及技術委員會補助大專學生研究計畫成果報告, NSTC 113-2813-C-034-052-E). 國家科學及技術委員會
- [13] Yin, H., Gu, L., Parmar, P., Xu, L., Guo, T., Fu, W., Zhang, Y., & Zheng, T. (2025). FLEX: A large-scale multi-modal multi-action dataset for fitness action quality assessment (arXiv:2506.03198). arXiv. <https://arxiv.org/abs/2506.03198>
- [14] Parmar, P., Gharat, A., & Rhodin, H. (2022). Domain knowledge-informed self-supervised representations for workout form assessment. In Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXXVIII (pp. 105–123). Springer.
- [15] Wang, L., Huang, B., Zhao, Z., Tong, Z., He, Y., Wang, Y., Wang, Y., & Qiao, Y. (2023). VideoMAE V2: Scaling video masked autoencoders with dual masking. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 14549–14560)
- [16] Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Guzdial, M., Yang, A., Fan, A., Goyal, A., Hartshorn, A., Koubaa, A., Yadav, A., Najork, M., Shou, D., Bhatia, S., Chen, S., Goyal, S., Lee, S., Stoica, I., & Meta Llama Team. (2024). The Llama 3 herd of models (Preprint No. arXiv:2407.21783). <https://arxiv.org/abs/2407.21783>
- [17] Yang, A., Yang, B., Hui, B., Huang, C., Liu, C., Li, J., Ma, J., Wang, J., Zhang, J., Zhao, L., Zhu, L., Wang, Z., & Qwen Team. (2024). Qwen2.5 technical report (Preprint No. arXiv:2412.15115). <https://arxiv.org/abs/2412.15115>
- [18] Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- [19] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). Ragas: Automated evaluation of retrieval augmented generation (Preprint No. arXiv:2309.15217). <https://arxiv.org/abs/2309.15217>
- [20] Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>